系统开发方案

战略咨询智能支持系统

开发工作思路与技术方案

基础数据准备 · 大数据分析 · 智能问数Agent

基于《战略咨询智能支持》需求文档

2026年3月

目　　录

一、系统总体开发思路 3

1.1 系统定位与目标

1.2 总体架构设计

1.3 分期建设路线

二、基础数据准备 5

2.1 数据源全景图

2.2 各类数据详细规格

2.3 数据治理与质量体系

三、大数据分析方案 9

3.1 七大核心分析引擎

3.2 分析流水线与调度

四、智能问数Agent方案 13

4.1 Agent架构设计

4.2 核心能力拆解

4.3 技术选型与实现路径

4.4 典型场景与对话流

五、技术栈与团队建议 16

六、风险与建议 17

一、系统总体开发思路

1.1 系统定位与目标

战略咨询智能支持系统是一个面向高端智库的科技战略研究数字化平台，核心使命是**"以科学方法支撑科学咨询，以科学咨询支撑科学决策"**。系统需打通从数据采集、技术分析、趋势研判到报告生成的全链路闭环。

> **核心定位：**不是简单的数据分析平台，而是"人机协同"的智库大脑——系统提供数据驱动的智能分析能力，专家提供经验判断与战略洞察，两者深度融合产出高价值咨询成果。

系统需达成三个层次的目标：

- **效率目标：**将传统人工调研从数周压缩至数天，报告生成从手工撰写变为AI辅助+人工审核
- **质量目标：**基于全量数据分析而非抽样，覆盖论文、专利、项目、资讯多源异构数据
- **创新目标：**通过智能问数Agent实现"自然语言即分析"，让非技术人员进行深度数据探索

1.2 总体架构设计

建议采用**"四层三中台"**架构，确保系统可扩展、可维护：

架构层次	核心内容	关键技术组件
数据层	多源数据采集、清洗、存储、治理	数据湖(MinIO/HDFS)、数据仓库(ClickHouse/StarRocks)、图数据库(Neo4j)、向量库(Milvus)、ES全文检索
算法层	NLP处理、知识图谱、聚类分析、趋势预测、网络分析	大语言模型(GPT-4/文心/通义)、Spark MLlib、PyTorch、NetworkX
服务层	业务中台（7大模块API）、数据中台（统一查询）、AI中台（模型服务）	微服务(Spring Cloud/K8s)、API Gateway、Airflow任务调度、Kafka消息队列
应用层	Web前端、可视化看板、智能问数Agent、报告生成器	React/Vue3、ECharts/AntV、LangChain Agent、PDF/Word导出引擎

1.3 分期建设路线

建议分三期建设，每期约6个月，总周期18个月：

第一期：数据底座与基础分析（第1-6月）

- **数据底座搭建：**完成论文、专利、科研项目三大核心数据源接入、清洗、入库
- **知识图谱V1：**科技实体识别、关系抽取，形成初版科技知识图谱
- **核心功能上线：**科技实体清单管理、论文/专利/科研项目多维分析与可视化
- **技术体系模块：**在线编辑器、案例库、专家交互基础功能

第二期：智能分析与专家协同（第7-12月）

- **高级分析引擎：**颠覆性技术识别、技术趋势分析、聚类分析、社会网络分析
- **专家协同系统：**德尔菲问卷全流程、专家意见管理、技术路线图编辑器
- **报告生成系统：**研究报告管理、洞察报告、战略咨询报告AI辅助生成
- **媒体聚焦与预警：**舆情监控、技术动态预警、订阅推送

第三期：智能问数与全面优化（第13-18月）

- **智能问数Agent：**自然语言查询→SQL生成→自动可视化→看板→一键报告
- **数据看板系统：**拖拽式看板编辑器、多页集合、全局联动筛选
- **一键报告生成：**模板引擎、AI智能摘要、数据校验闭环
- **全面优化：**系统性能调优、模型精度提升、用户体验打磨

二、基础数据准备

2.1 数据源全景图

系统运转需要六大类基础数据，构成完整的科技情报数据底座：

#	数据类别	数据来源	核心字段	规模估算
1	**学术论文**	WoS、Scopus、CNKI、万方、PubMed、arXiv	标题、摘要、关键词、作者、机构、引用	亿级记录
2	**专利数据**	CNIPA、USPTO、EPO、WIPO、PatSnap	标题、摘要、IPC分类、申请人、权利要求	亿级记录
3	**科研项目**	NSFC、科技部、NIH、NSF、EU Horizon	项目名称、承担单位、经费、领域、周期	千万级
4	**科技实体**	工商数据、高企名单、独角兽榜单	企业名称、领域、专利数、融资、创新指数	百万级
5	**新闻舆情**	科技媒体、政府网站、行业报告	标题、正文、来源、情感、关联实体	千万级/年
6	**专家库**	院士名单、杰青/优青、高被引学者	姓名、机构、方向、H指数、代表作	十万级

2.2 各类数据详细规格

（一）学术论文数据

采集范围：国际（WoS核心合集、Scopus、PubMed、IEEE Xplore、arXiv）+ 国内（CNKI、万方、维普）。时间跨度建议覆盖近20年（2005年至今）。

字段分类	具体字段	用途
基础信息	标题、摘要、关键词、DOI、出版年份	内容检索、主题聚类
作者信息	作者姓名、ORCID、所属机构、国家	合作网络、人才画像
期刊信息	期刊名称、ISSN、影响因子、学科分类	质量评估、领域归属
引用信息	被引次数、参考文献列表、引用网络	影响力分析、知识溯源
全文/扩展	全文文本（如可获取）、基金资助信息	深度语义分析

预处理要求：作者姓名消歧（ORCID+机构+共引聚类）、机构名称标准化（统一"清华大学""Tsinghua University"等变体）、关键词归一化、DOI去重。

（二）专利数据

采集范围：五大局（CNIPA/USPTO/EPO/JPO/KIPO）+ PCT国际申请。推荐数据商：智慧芽(PatSnap)。

字段分类	具体字段	用途
基础信息	标题、摘要、权利要求书、说明书	技术内容分析
分类信息	IPC分类号（大类→小类）、CPC分类	技术领域归属、IPC分布
权利人	申请人/专利权人、发明人、代理机构	机构竞争力、发明人网络
法律状态	申请日、授权日、法律状态、专利族	有效性判断、布局策略
引用信息	引用专利、被引专利、引用论文	技术溯源、影响力评估

（三）科研项目数据

核心字段	说明	分析用途
项目名称/编号	NSFC、重点研发计划等	唯一标识与检索
承担单位/负责人	依托单位、项目PI	机构能力画像、人才评估
资助金额/类型	经费总额、项目类型	投入产出分析
研究领域/关键词	学科代码、项目关键词	领域布局分析
起止时间/状态	项目周期、当前状态	趋势分析、活跃度
成果关联	关联论文、专利、获奖	投入产出效率评估

（四）科技实体、新闻舆情与专家库

- **科技实体：**工商注册信息、行业分类、融资轮次/金额、专利持有量、核心产品线；需构建综合创新指数 = f(专利数, 论文数, 项目数, 融资额, 市场热度)
- **新闻舆情：**每日增量采集科技媒体（36氪、TechCrunch、MIT Tech Review等）和政策网站；NLP处理链：实体识别→情感分析→事件抽取→主题分类→关联科技实体
- **专家库：**院士库、杰青/优青名录、高被引学者（Clarivate HCR）；核心字段包括研究方向、H指数、代表性成果

2.3 数据治理与质量体系

层	治理环节	关键动作	工具/方法
L1	**数据采集**	多源异构数据统一接入、增量采集、断点续传	Scrapy/API对接/数据商SDK
L2	**数据清洗**	去重、去噪、格式标准化、编码统一	Spark ETL、正则规则库
L3	**实体融合**	作者消歧、机构标准化、跨库实体对齐	余弦相似度+聚类、ORCID
L4	**知识构建**	实体-关系抽取、知识图谱构建、向量化索引	NER模型、Neo4j、Milvus
L5	**质量监控**	完整性/一致性/时效性校验、异常告警、质量报告	Great Expectations、自研规则引擎

> **关键提醒：**数据准备阶段预计占项目总工作量的40%-50%，是决定系统价值的基础。建议第一期优先保证论文+专利+项目三大核心数据的质量，舆情和实体数据可渐进补充。

三、大数据分析方案

3.1 七大核心分析引擎

基于需求文档中的七大模块功能，需要构建七个核心分析引擎，每个引擎对应明确的输入数据、算法方法和输出成果：

引擎一：科技实体分析引擎

维度	内容
输入数据	科技实体库、专利数据、论文数据、融资数据、新闻舆情
分析内容	① 多维画像：技术领域分布、创新能力评分、区域分布 ② 创新指数计算：加权综合评分模型 ③ 实体对标：同领域横向对比、竞争态势分析
核心算法	TF-IDF/BM25检索 + 余弦相似度去重 + 多指标加权评分 + 聚类分群
输出成果	实体画像卡片、创新排行榜、区域分布热力图、对标分析报告

引擎二：颠覆性技术识别引擎

维度	内容
输入数据	论文摘要+关键词、专利权利要求、科技新闻、科研项目
分析内容	① 技术新颖性检测：新兴关键词爆发识别 ② 技术成熟度评估：基于Gartner Hype Cycle框架 ③ 颠覆性潜力评分：跨领域影响+增长速率+参与主体多样性
核心算法	时间序列异常检测(突增关键词) + LDA/BERTopic主题建模 + 技术生命周期S曲线拟合 + 多维度加权评分
输出成果	颠覆性技术候选清单（含置信度）、前沿技术雷达图、技术关联网络

内容 **输入数据**论文全量数据、专利全量数据、科研项目数据 **分析内容**① 关键词热度与趋势（词云+时间序列）

② 全球分布（国家/机构排名、地图可视化）

③ 作者/发明人合作网络

④ IPC分类分布与交叉分析

⑤ 二维交叉相关性矩阵 **核心算法**TextRank/KeyBERT关键词提取 + 时间衰减热度公式 + 共现矩阵构建 + 力导向图布局 + 卡方检验(偏离度) **输出成果**论文/专利分析仪表盘、国家竞争力排名、机构合作网络图、IPC技术矩阵

引擎四：社会网络分析引擎

维度	内容
输入数据	论文合著关系、专利共同申请、项目合作关系、引用网络
分析内容	① 网络构建：节点(实体/人/机构) + 边(合作/引用/竞争) ② 中心性分析：度中心性、中介中心性、接近中心度、特征向量中心性 ③ 社区发现：Louvain/Leiden聚类算法 ④ 关键桥梁节点识别
核心算法	NetworkX/igraph图计算 + Louvain社区检测 + PageRank + 嵌入性指标 + 力导向可视化
输出成果	社会网络关系图、关键节点排名、社区结构图、桥梁节点识别

引擎五：技术趋势与预警引擎

维度	内容
输入数据	时间序列化的论文/专利/项目/新闻数据、知识图谱
分析内容	① 技术热点追踪：滑动窗口热度计算、突增检测 ② 技术交叉关联：跨领域共现分析、融合趋势识别 ③ 机构合作趋势：合作强度时序演化 ④ 动态预警：异常热度/情感波动/突发事件自动告警
核心算法	ARIMA/Prophet时序预测 + 突变检测(CUSUM/Bayesian) + Granger因果检验(滞后效应) + 规则引擎(阈值/增速/复合触发)
输出成果	技术热度排行榜、趋势折线图/河流图、预警信息流、预警建议分级

引擎六：聚类与共性网络引擎

维度	内容
输入数据	论文/专利的TF-IDF或语义向量、关键词共现矩阵
分析内容	① 主题聚类：自动将文献聚合为技术主题簇 ② 共性网络：术语关系矩阵构建、语义网络拓扑分析 ③ 三级筛选机制：初级→中间→最终清单逐步精炼 ④ 高产作者统计：各主题下核心研究者识别
核心算法	K-Means/DBSCAN/层次聚类 + BERTopic主题建模 + 共现频次+语义相似度+上下文相关度综合评分 + 初/中/终三级加权筛选模型
输出成果	领域知识聚类清单、术语关系矩阵、语义网络图、技术清单（含三级筛选）

引擎七：媒体聚焦与舆情引擎

维度	内容
输入数据	新闻舆情数据、科技实体库、技术清单、知识图谱
分析内容	① 媒体-技术耦合分析：媒体关注与技术发展的相关性 ② 情感趋势：正/中/负情感分布及演化 ③ 热点检测：短期异常增长、来源集中度分析 ④ 智能推荐：基于知识图谱的相关主题/机构推荐
核心算法	BERT情感分类 + 滞后相关系数(媒体vs技术产出) + 突发事件检测(流量+情感复合规则) + Personalized PageRank推荐
输出成果	媒体聚焦仪表盘、耦合度分析面板、热点事件时间线、应急简报自动生成

3.2 分析流水线与调度

七大引擎并非独立运行，而是通过**DAG（有向无环图）编排**实现级联调度：

> **典型分析流水线：**
> 数据采集(每日) → 数据清洗/入库 → 关键词提取/NER实体识别 → 知识图谱更新 → 热度/趋势计算(增量) → 聚类更新(周级) → 预警规则扫描(实时) → 仪表盘刷新

调度策略建议：

- **实时层：**舆情采集、预警规则扫描、突发事件检测 → Kafka流处理 + Flink

- **小时级：**热度统计更新、新入库数据的NLP处理 → Airflow定时任务
- **天级：**日报生成、知识图谱增量更新、全量统计刷新 → Spark批处理
- **周级：**聚类模型重训练、社会网络重新计算、趋势预测模型更新 → 离线GPU集群

四、智能问数Agent方案

4.1 Agent架构设计

智能问数Agent是系统的"最后一公里"——它将前面所有的数据和分析能力，通过自然语言接口暴露给业务用户。推荐采用**多Agent协同架构**：

> **架构核心理念：**不是一个"大一统"Agent，而是一个"路由器 + 专家团"模式。主控Agent负责意图理解和任务分配，多个专业子Agent分别处理SQL查询、图表生成、报告撰写等具体任务。

Agent角色	职责	核心能力
Router Agent (主控路由)	接收用户自然语言输入，理解意图，分发给对应子Agent	意图分类、实体识别、上下文管理、多轮对话
SQL Agent (查询生成)	将自然语言转化为SQL，查询数据仓库，返回结构化结果	Text-to-SQL、Schema映射、查询优化、结果缓存
KG Agent (图谱查询)	对知识图谱进行查询和推理，回答关系类问题	Cypher生成、子图检索、路径推理、实体链接
Viz Agent (可视化)	根据数据特征自动选择图表类型并渲染	数据→图表规则引擎、ECharts配置生成、交互联动
Report Agent (报告生成)	基于分析结果自动生成结构化报告	模板解析、AI文本生成、图表嵌入、数据校验
QA Agent (知识问答)	基于RAG对非结构化内容进行知识问答	向量检索、文档片段召回、答案生成与引用溯源

4.2 核心能力拆解

能力一：自然语言→SQL查询

这是智能问数的核心难点。技术实现路径：

1. **语义层（Semantic Layer）构建：**
   - 为每张物理表和字段建立**业务别名映射**（如 paper_count → "论文数量"）
   - 维护**业务术语词典**（如"高被引" = 被引次数 > 100）
   - 定义**指标计算逻辑**（如"创新指数" = 0.3*专利数 + 0.3*论文数 + 0.2*项目数 + 0.2*融资额）

    - 配置**表间关联关系**（外键、多对多关系表）
2. **Text-to-SQL流程：**
    - Step 1：意图分类 → 判断查询类型（聚合统计/排名/趋势/对比/明细查询）
    - Step 2：实体抽取 → 识别字段名、指标名、时间表达式、数值条件
    - Step 3：Schema选择 → 根据实体匹配最相关的表和字段（Top-K相关表）
    - Step 4：SQL生成 → LLM基于Schema+语义层+Few-shot示例生成SQL
    - Step 5：SQL校验 → 语法检查 + 安全检查(防注入) + 执行计划评估
    - Step 6：执行+缓存 → 提交数据库执行，结果缓存，相似查询复用
3. **纠错与容错：**同义词词典自动扩展、拼写纠错、模糊匹配兜底、执行失败自动重试(修正SQL)

能力二：自动可视化匹配

数据特征	推荐图表	判断规则
1维度 + 1指标（时间序列）	折线图	维度为时间类型
1维度 + 1指标（分类）	柱状图/条形图	分类数 ≤ 20
1维度 + 1指标（占比）	饼图/环形图	分类数 ≤ 8 且有"占比"语义
2维度交叉	热力图/矩阵图	两个分类维度交叉
多指标对比	雷达图	3-8个指标、1-3个实体对比
地理信息	地图	含国家/省份/城市维度
网络关系	力导向图	数据含节点+边结构
无明确图表映射	表格	默认兜底

能力三：数据看板编辑与管理

- **拖拽式编辑器：**组件库（图表/筛选器/文本/图片） + 画布自由布局 + 实时预览
- **数据绑定：**每个图表组件绑定一条已保存的NL查询或SQL，支持参数化动态刷新
- **多页集合：**支持将多个看板聚合为"看板集"，导航目录+全局筛选器联动
- **分类管理：**层级文件夹 + 多标签 + 全局搜索（名称/标签/创建者）

能力四：一键报告生成

- **模板引擎：**用户自定义Word/PDF模板，预设占位符（文本/表格/图表位）
- **AI摘要：**LLM对查询结果自动生成描述段落，识别关键变化（增长率、异常值、主要构成）

- **数据校验：**报告生成后自动重新执行所有查询，比对数据一致性，不一致处标注警告
- **输出格式：**PDF / Word / PPT / 在线预览，支持带权限的分享链接

4.3 技术选型与实现路径

技术环节	推荐方案	备选方案
LLM底座	GPT-4o / Claude 3.5（海外） 通义千问 / 文心4.0（国内）	开源DeepSeek-V3/Qwen2.5自部署
Agent框架	LangChain + LangGraph	AutoGen / CrewAI / 自研
Text-to-SQL	LLM + 语义层 + Few-shot	DIN-SQL / DAIL-SQL微调模型
向量检索(RAG)	Milvus + BGE-M3 Embedding	Qdrant / Weaviate / pgvector
图谱查询	Neo4j + Cypher + LLM翻译	NebulaGraph / TigerGraph
可视化引擎	ECharts + AntV G2/G6	D3.js / Plotly
报告引擎	docxtpl(Word) + WeasyPrint(PDF)	Puppeteer HTML→PDF
看板编辑器	自研(React-Grid-Layout)	Apache Superset / Metabase二开

4.4 典型场景与对话流

场景一：数据查询

👤 "2020-2025年全球量子计算领域论文发表趋势是怎样的？"

🤖 Router → SQL Agent → 生成SQL: SELECT year, COUNT(*) FROM papers WHERE field='量子计算' AND year BETWEEN 2020 AND 2025 GROUP BY year → Viz Agent → 折线图 → "2020-2025年，全球量子计算论文从12,340篇增长至28,670篇，年均复合增长率18.4%，2023年起增速显著加快。"

场景二：知识问答

👤 "哪些机构在固态电池领域的专利布局最强？"

🤖 Router → SQL Agent(专利统计) + KG Agent(机构关系) → 返回Top10机构排名+合作网络 → Viz Agent → 柱状图+网络图 → Report Agent生成分析段落

场景三：一键报告

👤 "帮我生成一份人工智能领域2025年度技术发展洞察报告"

🤖 Router → SQL Agent(多维统计) + KG Agent(关系数据) + Report Agent → 按模板填充数据+图表+AI摘要 → 数据校验 → 输出PDF

五、技术栈与团队建议

5.1 推荐技术栈全景

层次	技术选型	说明
前端	React 18 / Vue 3 + TypeScript	看板编辑器建议React(生态更丰富)
可视化	ECharts 5 + AntV G6(网络图)	G6专攻关系网络可视化
后端	Java(Spring Cloud) / Python(FastAPI)	Java做业务服务，Python做AI/算法
数据仓库	ClickHouse / StarRocks	OLAP引擎，支持亿级数据秒级查询
图数据库	Neo4j Enterprise	知识图谱存储与图计算
向量数据库	Milvus / Qdrant	语义检索、相似文献推荐
全文检索	Elasticsearch 8	论文/专利/新闻全文检索
大模型	GPT-4o API / 通义千问 / DeepSeek	按安全要求选云端或本地部署
任务调度	Apache Airflow	DAG编排所有分析流水线
消息队列	Apache Kafka	实时舆情流处理
容器化	Docker + Kubernetes	微服务部署与弹性扩容

5.2 团队配置建议

角色	人数	核心技能
项目经理/产品经理	1-2人	智库/科技情报领域经验，需求管理
前端开发	3-4人	React/Vue、可视化(ECharts/G6)、看板编辑器
后端开发	4-5人	Java/Python微服务、数据库、API设计
数据工程师	3-4人	ETL、数据治理、Spark、数据质量
算法/AI工程师	3-4人	NLP、知识图谱、LLM应用、Text-to-SQL
测试工程师	2人	功能测试、数据校验、性能测试
运维/DevOps	1-2人	K8s、CI/CD、监控告警
合计	**17-23人**	

六、风险与建议

风险类型	风险描述	影响等级	应对措施
数据获取	论文/专利数据源的授权费用高，部分数据商接口限流	高	提前洽谈数据商合作，评估OpenAlex等开放数据源替代方案
数据质量	多源数据格式不统一，实体消歧准确率不足	高	建立严格的数据治理流程，预留充分的数据清洗时间
LLM幻觉	Text-to-SQL生成错误SQL、报告AI摘要出现事实性错误	中高	强制SQL校验+人工审核机制；报告生成后自动数据比对
性能瓶颈	亿级数据上的复杂查询响应慢	中	预聚合+物化视图+查询缓存；ClickHouse分区优化
需求膨胀	功能模块多达7大类，需求文档极其详细，范围蔓延风险大	中高	严格分期交付，MVP先行，每期聚焦核心功能
安全合规	涉及国家科技战略数据，安全等级要求高	高	专网部署/私有化LLM，数据分级分类，等保三级

核心建议：

① **数据先行：**第一期至少50%工时投入数据准备，数据质量决定一切后续分析的价值

② **MVP迭代：**每个模块先做"能用"版本快速上线，再根据用户反馈逐步优化

③ **智能问数分步走：**先实现结构化数据的NL-to-SQL查询，再逐步扩展到图谱查询和自由问答

④ **专家深度参与：**颠覆性技术识别、技术清单筛选等环节，算法只能做"候选"，最终决策必须由领域专家把关

⑤ **安全底线：**涉及科技战略的系统，优先考虑私有化部署和国产大模型

本报告基于《战略咨询智能支持》需求文档分析整理，仅供技术方案讨论参考。具体实施方案需结合实际技术环境、预算和团队情况进一步细化。

编制日期：2026年3月